TRM Predict

Analítica predictiva en la nube para el riesgo cambiario en Colombia

Resumen de avance · 21 de octubre de 2026

Enlaces del proyecto	
Tablero web (AWS)	http://trm-predict-dev-alb-496593350.us-east-1.elb.amazonaws.com/
Predicción del día (JSON)	http://trm-predict-dev-alb-496593350.us-east-1.elb.amazonaws.com/api/predict
Modelos y métricas (JSON)	http://trm-predict-dev-alb-496593350.us-east-1.elb.amazonaws.com/api/model
Historia de la TRM (JSON)	http://trm-predict-dev-alb-496593350.us-east-1.elb.amazonaws.com/api/history
Health check	http://trm-predict-dev-alb-496593350.us-east-1.elb.amazonaws.com/health
Repositorio GitHub	https://github.com/Sebas-409/proyecto-integrador-trm
Código del método del codo	github.com/.../src/pipeline/elbow.py
Figuras y resultados	github.com/.../reports

Los enlaces de AWS funcionan mientras la infraestructura esté encendida. Si se ejecuta terraform destroy y luego apply, el balanceador cambia de dirección.

1. Objetivo

Pronosticar, para el siguiente día hábil, la dirección de la TRM (COP/USD), su valor esperado y la probabilidad de un movimiento fuerte, para que hogares que reciben remesas y mipymes importadoras decidan cuándo comprar o vender dólares, o cuándo cubrirse. Apunta al ODS 8 (meta 8.10) y al ODS 10 (meta 10.c, costo de las remesas).

2. Lo que se ha realizado

Etapa	Qué se hizo	Herramientas
Adquisición	TRM oficial (datos.gov.co), mercados globales (Yahoo Finance), BTC/ETH (Binance) y titulares de La República por web scraping con índice de sentimiento.	requests, BeautifulSoup
Preparación	Limpieza, integración por fecha y 43 variables: retornos, volatilidades, medias móviles, rezagos y sentimiento.	pandas, NumPy
EDA	Serie histórica, distribución de retornos, correlaciones (fijas y móviles) y efecto del día de la semana.	matplotlib
No supervisado	PCA, K-Means, jerárquico (Ward), DBSCAN para días anómalos y reglas de asociación (Apriori y FP-Growth). Se agregó K-Means con k elegido por el método del codo.	scikit-learn, mlxtend
Supervisado	Regresión (valor), clasificación (alza/baja) y riesgo de movimiento fuerte; Grid y Random Search con validación temporal; explicabilidad con SHAP y LIME.	scikit-learn, SHAP, LIME
API y tablero	API REST con predicción, escenarios "qué pasaría si", historia y métricas; tablero web.	FastAPI, Docker
Nube AWS	VPC, S3 con réplica a us-west-2, RDS, ALB + Auto Scaling, Lambdas de ingesta y ETL diarios, CloudWatch y Budgets, todo con Terraform.	Terraform, AWS

3. Resultados de los modelos

Periodo de prueba: 18-dic-2024 a 17-oct-2026 (432 días; entrenamiento con 1.727 días anteriores).

Tarea	Mejor modelo	Resultado en prueba	Referencia
Valor de la TRM (retorno)	Gradient Boosting	RMSE 2,4 % menor que la caminata aleatoria	Caminata aleatoria
Dirección (alza/baja)	Gradient Boosting	AUC 0,566 · F1 0,541	AUC 0,5 (azar)
Movimiento fuerte	Random Forest	AUC 0,585	AUC 0,5 (azar)

La TRM diaria es casi impredecible, así que la ventaja de los modelos sobre el azar y sobre la caminata aleatoria es pequeña.

4. Clusterización con el método del codo (nuevo)

Con los clústeres buscamos agrupar los días en regímenes de mercado sin decirle al algoritmo cuáles son, y ver si el régimen de hoy cambia la dirección probable y el riesgo de la TRM de mañana.

Cómo se hizo

Usamos 2.159 días hábiles (2017-2026) y 9 variables: la volatilidad a 20 días y el retorno a 5 días de la TRM, los retornos a 5 días de VIX, DXY, Brent y BTC, y la volatilidad de Brent, BTC y S&P 500. Antes de agrupar recortamos las colas al percentil 1-99, porque sin ese recorte los días de marzo de 2020 dominan las distancias, y estandarizamos con StandardScaler.

Para la curva del codo entrenamos K-Means con k de 1 a 10 (n_init = 10, semilla fija) y guardamos la inercia (WCSS) de cada k. El codo no se eligió a ojo: tomamos el k cuya inercia queda más lejos de la recta que une k = 1 con k = 10, que es la idea del algoritmo Kneedle. Salió k = 4. Como contraste calculamos silhouette, Davies-Bouldin y Calinski-Harabasz para cada k, y usamos PCA a 2 componentes solo para dibujar los grupos.

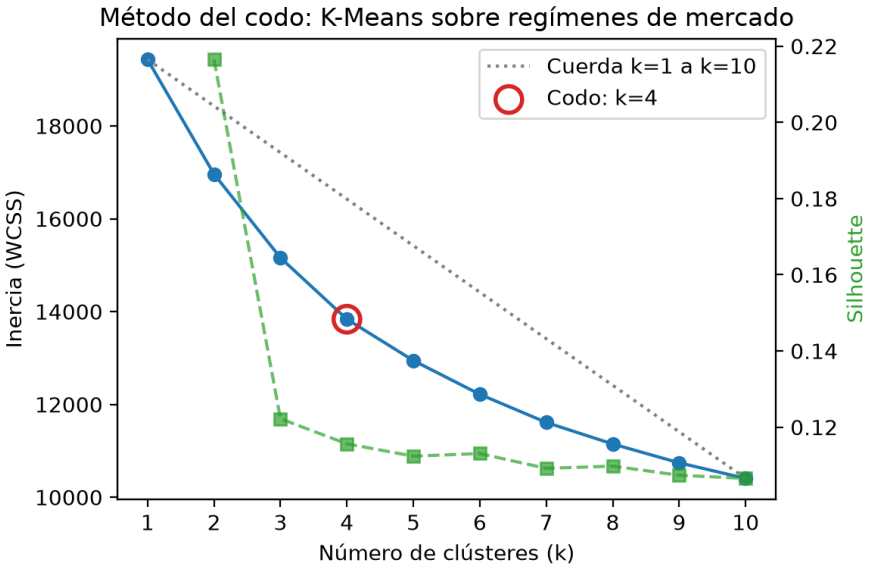


Figura 1. Inercia por k (azul) y silhouette (verde). El codo está en k = 4.

Regímenes encontrados

Clúster	Días	% días	TRM sube al día siguiente	Rasgo
0 · Calma	752	35 %	50,8 %	Volatilidad baja en todo
1 · Apetito por riesgo (peso se aprecia)	754	35 %	43,8 %	TRM, VIX y DXY a la baja
2 · Aversión al riesgo (dólar sube)	606	28 %	51,3 %	VIX +12 %, TRM +1,6 % en 5 días
3 · Crisis / alta volatilidad	47	2 %	42,6 %	Casi todo mar-may 2020; el día siguiente es el doble de volátil

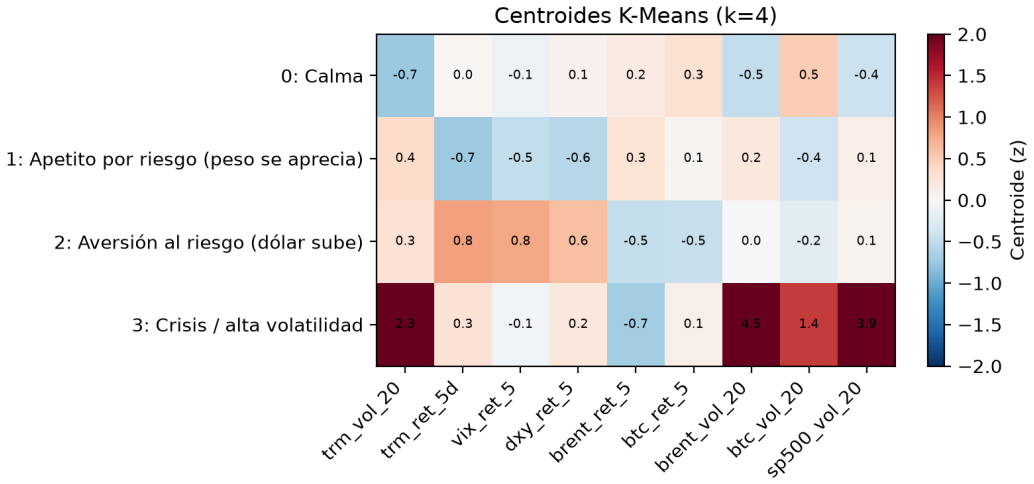


Figura 2. Centroides de cada clúster en unidades estandarizadas (z).

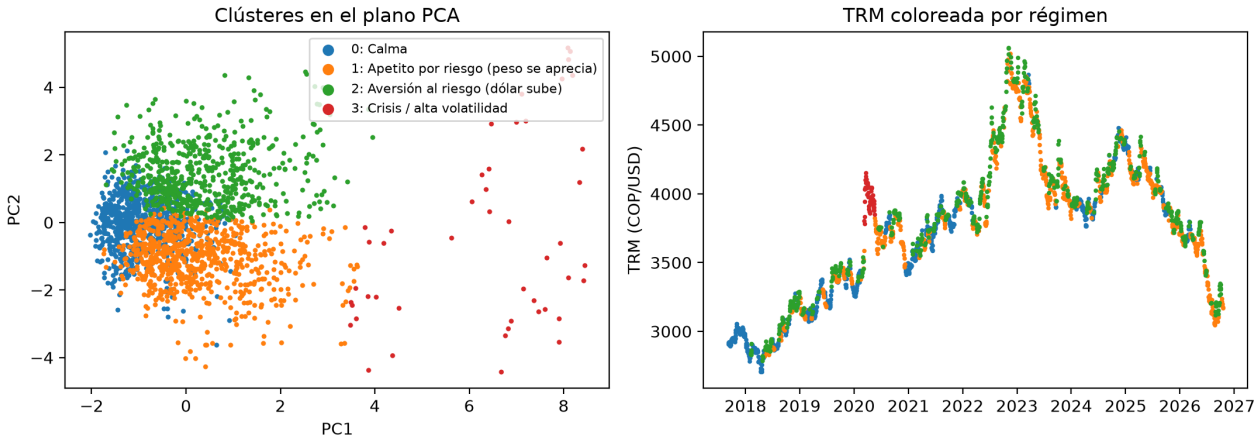


Figura 3. Clústeres en el plano PCA (izq.) y serie de la TRM coloreada por régimen (der.).

Interpretación

El régimen dice algo sobre el día siguiente. En apetito por riesgo la TRM sube solo el 44 % de las veces, y en crisis la volatilidad del día siguiente se duplica, que es justo lo que mide el indicador de "movimiento fuerte" de la API. El grupo de crisis quedó formado casi solo por días de marzo a mayo de 2020 sin que le marcáramos el COVID al algoritmo.

El silhouette con k = 4 es bajo (0,116). En series financieras pasa seguido porque los regímenes se solapan. Con k = 2 el silhouette sube a 0,22, pero esa partición solo separa la crisis del resto.

El régimen se podría mostrar en el tablero ("en qué régimen estamos hoy") o usar como variable extra en los modelos supervisados.

5. Cómo reproducirlo

Desde la raíz del repositorio, con el entorno instalado (pip install -r requirements.txt):

Paso	Comando
Ingesta	python -m src.ingest.run
Preparación	python -m src.pipeline.prepare
EDA	python -m src.pipeline.eda
No supervisado	python -m src.pipeline.unsupervised
Clusterización por el codo	python -m src.pipeline.elbow
Modelos	python -m src.pipeline.train
API local	uvicorn api.app:app --port 8000

Salidas del codo: reports/figures/codo_*.png, reports/elbow_curve.csv, reports/elbow_clusters_profile.csv, reports/elbow.json y data/processed/clusters_codo.csv.

Aviso: proyecto académico; no es una recomendación de inversión.